

Étude de Cas : Data Quality & Gouvernance des Données



Un projet complet d'audit et d'amélioration de la qualité des données
Une approche complète d'évaluation et d'amélioration de la qualité des données basée sur un pipeline dockerisé à 6 couches fonctionnelles.

Deadline : 15 janvier 2026.

ICOM - Master 2 BI & Analytics

Année universitaire 2025-2026

Mabrouk HANNACHI

Objectifs Pédagogiques du Projet



Sélection & Évaluation

Choisir et analyser un dataset réel provenant de sources publiques (Kaggle, OpenDataSoft, Data.gouv.fr)



Profilage & Exploration

Explorer les anomalies de qualité avec Evidently, Sweetviz ou avec power BI et analyses manuelles approfondies



Nettoyage & Réconciliation

Implémenter des processus de nettoyage selon les 6 piliers de qualité des données



Pipeline Complet

Créer une architecture Data Quality avec validation, monitoring et gouvernance centralisée

Architecture Technique proposée : Les 6 Couches

01

Stockage - MariaDB (Port 3306)

Base source et tables nettoyées pour toutes les transformations de données

03

Validation - Great Expectations (Port 8080)

Tests de qualité automatisés avec suite d'expectations complète

05

Gouvernance - OpenMetadata (Port 8585)

Catalogue centralisé avec data lineage et documentation complète

02

Exploration - Jupyter + Evidently (Port 8888) ou Power BI

Profilage automatisé et analyse exploratoire des anomalies de qualité

04

Visualisation - Apache Superset (Port 8088) ou power BI

Dashboards interactifs pour monitoring en temps réel des KPI DQ

06

Orchestration - Apache Airflow (Port 8090)

Automatisation du pipeline avec scheduling et gestion des erreurs

Phase 1 : Sélection du Dataset

Sources Autorisées

- **Open Data Soft** : données santé, transport, environnement, économie
- **Kaggle** : customer churn, healthcare, e-commerce, finance
- **Data.gouv.fr** : SIRENE, cadastre, accidents, examens scolaires

Critères Obligatoires

Minimum 10 000 lignes (idéalement 50 000+), au moins 10 attributs différents, types variés (texte, numérique, dates), présence d'anomalies et contexte business clair.



 **Deadline : 20 novembre 2025**

Livable : Document PDF (2 pages) avec URL, description métier, statistiques et justification du choix

Phase 2 : Profilage et Exploration



Profilage Automatique

Génération de rapports HTML avec Evidently et Sweetviz pour identifier distributions, statistiques et anomalies automatiquement



Analyse Manuelle

Exploration approfondie dans Jupyter : valeurs manquantes, doublons, outliers, cohérence inter-colonnes et formats invalides




Cartographie Complète

Rapport de 8-10 pages documentant toutes les anomalies détectées avec impact métier et plan de redressement priorisé

Deadline : 5 décembre 2025 - Cette phase pose les fondations de toutes les transformations à venir.



Phase 3 : Les 6 Piliers de la Qualité



Phase 4 : Validation avec Great Expectations

Suite d'Expectations Complète

Création de **minimum 10 expectations** automatisées couvrant tous les piliers de qualité

- Complétude : colonnes non nulles, taux minimum
- Exactitude : formats regex, types de données
- Validité : ensembles de valeurs, plages autorisées
- Cohérence : comparaisons inter-colonnes
- Unicité : clés primaires, combinaisons uniques
- Actualité : dates récentes, pas de futures



Checkpoints et Alerting

Configuration de l'exécution automatique avec actions sur échec : stockage des résultats, mise à jour des Data Docs et notifications Slack.

Deadline : 28 décembre 2025

Phase 5 : Dashboards de Monitoring

1

Vue d'Ensemble

Score global, jauge de complétude, bar chart des 6 piliers et top colonnes problématiques

2

Tendances Temporelles

Évolution du score global, area chart des piliers, heatmap par jour et box plot des distributions

3

Analyse Détaillée

Répartition des erreurs, top erreurs d'exactitude, flux de nettoyage Sankey et enregistrements problématiques

Configuration d'alertes automatiques lorsque le score DQ tombe sous 90%. Deadline : 10 janvier 2026

Phase 6 : Gouvernance avec OpenMetadata optionnel

Catalogue des Assets

Documentation complète de toutes les tables avec descriptions, propriétaires, fréquence de mise à jour et critères de qualité

Glossaire Métier

Minimum 15 termes métier définis avec synonymes et exemples concrets pour faciliter la communication

Data Lineage


Traçabilité complète du flux de données depuis la source jusqu'aux dashboards finaux avec analyse d'impact

Phase 7 : Orchestration & Rendu Final

- 1 — DAG Airflow Complet → optionnel
Pipeline automatisé avec 5 task groups : import/nettoyage, validation, KPI, rapports/alertes, archivage. Exécution quotidienne à 2h.
- 2 — Dépôt Git Structuré → Optionnel
Repository complet avec notebooks, SQL, configurations, 7 rapports PDF, screenshots et présentation de soutenance.
- 3 — Soutenance Orale → optionnel
Présentation de 15 minutes (20 slides max) + 5 minutes de questions.
Démonstration live des dashboards et du pipeline.

📌 **Obligatoire : Deadline Finale : 14 janvier 2026 à 23h59**

Rapport écrit et capture d'écran des dashboard DQ



Architecture Pipeline Data Quality Moderne

Cette section présente l'architecture d'un pipeline de données moderne, conçu pour garantir une qualité de données optimale. Elle couvre les étapes clés de la gestion de la donnée, de l'ingestion à la validation et au monitoring.

Les étudiants sont encouragés à proposer leurs propres choix technologiques, à condition de respecter les étapes fondamentales suivantes : stockage, exploration, validation, monitoring, traçabilité (lineage) et automatisation.



codepen.io

Pipeline de la qualité de donnée





Slack Technique : Choix des Outils

Cette section met en lumière les outils et approches techniques pour chaque phase du projet, offrant des alternatives pour une flexibilité accrue.

Exploration

Analysez vos données avec **Jupyter (Pandas)**, **Power BI**, ou directement via **SQL avancé** dans **MariaDB**.

Validation

Implémentez des tests de qualité avec **Great Expectations** ou utilisez des requêtes **SQL avancées** dans MariaDB.

Monitoring

Visualisez les KPI de qualité des données à l'aide d'**Apache Superset** ou de **Power BI**.

Gouvernance & Orchestration

Choisissez d'implémenter **OpenMetadata** et **Apache Airflow** (selon le schéma d'architecture) ou proposez une alternative adaptée.