
Phase 1 : Choix du Dataset

Base Sirene des entreprises et de leurs établissements (SIREN, SIRET)

1. Source et Accès aux Données

Nom du jeu de données : Base Sirene des entreprises et de leurs établissements (SIREN, SIRET) - Fichier StockEtablissement.

Producteur : INSEE (Institut National de la Statistique et des Études Économiques).

URL d'accès :
<https://www.data.gouv.fr/datasets/base-sirene-des-entreprises-et-de-leurs-etablissements-siren-siret>

2. Description Métier

Ce jeu de données recense l'état civil de tous les établissements (publics et privés) immatriculés au répertoire Sirene. Il est fondamental de distinguer les deux niveaux d'unités légales présents dans la base :

- L'Unité Légale (Siren - 9 chiffres) : L'entreprise en tant qu'entité juridique.
- L'Établissement (Siret - 14 chiffres) : L'objet de ce fichier. Il s'agit de l'unité de production géographiquement individualisée (magasin, usine, bureau, siège social).

Utilité et Cas d'usage :

- Identification unique pour les impôts et l'URSSAF.
- Analyse de zones de chalandise grâce aux coordonnées géographiques (coordonneeLambertAbscisseEtablissement).
- Suivi de la création/destruction d'activité par secteur (activitePrincipaleEtablissement) et par zone géographique.
- Ciblage d'entreprises par code postal ou activité.

3. Analyse de la Structure des Données

Identifiants : Le triplet siren, nic, siret permet une identification unique.

Statut de l'établissement : La colonne `etatAdministratifEtablissement` indique si l'établissement est Actif (A) ou Fermé (F).

Localisation : Adresse complète structurée (Numéro, Voie, Code Postal, Commune).

Activité (NAF) : Le code APE (`activitePrincipaleEtablissement`) classe le métier (ex: 32.12Z pour Fabrication d'articles de joaillerie).

Temporalité : `dateCreationEtablissement` et `dateDebut` permettent de calculer l'ancienneté.

4. Statistiques Descriptives Potentielles

Le fichier `StockEtablissement` étant volumineux (plusieurs dizaines de millions de lignes), voici les axes statistiques clés à présenter pour comprendre le tissu économique :

On pourrait distinguer le stock "vivant" du stock "historique" en faisant le pourcentage d'établissements Actifs ('A') vs Fermés ('F'). Une grande partie du fichier concerne des établissements fermés, ce qui nécessite un filtrage préalable pour toute étude de marché actuelle. Côté Topologie sectorielle, on pourrait identifier les activités dominantes grâce à `activitePrincipaleEtablissement`.

Exemple :

47.89Z : Autres commerces de détail sur éventaires et marchés (présent dans l'échantillon).

68.20B : Location de terrains et d'autres biens immobiliers (très fréquent).

On peut faire une cartographie de la densité économique avec le nombre d'établissements par Code Département (via les 2 premiers chiffres de `codePostalEtablissement`). Enfin, on peut visualiser les âges des établissements (`Année en cours - dateCreationEtablissement`).

5. Justification du Choix de la Table

Le choix de la table `StockEtablissement` plutôt que la table `StockUniteLegale` ou les fichiers de mises à jour quotidiennes se justifie par trois arguments majeurs. C'est une source fiable et réelle, on est capable de se poser des questions comme "Combien de boulangeries à Lyon ?". On a une exhaustivité historique car ce dataset conserve la trace des établissements fermés, contrairement à des bases de données commerciales souvent nettoyées.

Le dataset combine des données administratives (Siret), temporelles (Dates), géographiques et métiers, offrant le spectre d'analyse le plus large pour un data analyst.