

Phase 2 : Exploration et Cartographie des Données

Depuis ce lien : <http://localhost:8888/>

- On a créé un fichier de test pour vérifier que l'on retrouvait bien via Jupyter notre Dataset
- On a créé un fichier qui utilise YData plutôt que Evidently (car plusieurs erreurs indiquent que Evidently était introuvable, alors qu'il était bien installé, et après de nombreux tests, on a décidé de choisir une autre technologie) . Ce choix est aussi justifié par sa stabilité supérieure dans notre environnement Linux/Docker et sa capacité à générer des rapports HTML autonomes et exhaustifs sans dépendances graphiques lourdes.
- Ce fichier génère un rapport HTML complet avec plusieurs informations sur le dataset :
 - Nombre de variables, % de cellules vides
 - Variables : Pour chaque colonne, on aura un graphique de distribution.
 - Alerts : En haut du rapport, on listera les "Alerts" (ex: "dateCreationEtablissement has 20684 (20.6%) missing values").

 / work /

Name	Last Modified
•  Data_Quality_Profiling.ipynb	20 seconds ago
 rapport_exploration_sirene.html	1 minute ago
•  Test_fichier_trouvable.ipynb	9 days ago

Overview

Overview

Alerts59

Reproduction

Dataset statistics

Number of variables

54

Number of observations

100000

Missing cells

3085746

Missing cells (%)

57.1%

Total size in memory

41.2 MiB

Average record size in memory

432.0 B

Variable types

Text

47


DateTime

2

Unsupported

5

On est obligé de travailler avec le fichier de 100 000 lignes pour correspondre avec le contexte du projet et être en adéquation avec Superset mais ci-dessous un exemple avec toutes les lignes du fichier :



Bon, ce ne sera pas possible de voir cette version, car trop compliqué de faire tourner le docker pour gérer cette taille de fichier.

1. Synthèse du Profilage Automatique

Le rapport généré le 04/02/2026 sur l'échantillon StockEtablissement_utf8_100000.csv a révélé les métriques globales suivantes :

- Volume : ~100 000 observations (lignes) pour une cinquantaine de variables.
- Doublons : 0 ligne dupliquée détectée (Intégrité structurelle OK).
- Qualité Globale : Le dataset présente une bonne complétude générale, à l'exception critique des champs temporels.

siret

Text

Unique

Distinct	100000
Distinct (%)	100.0%
Missing	0
Missing (%)	0.0%
Memory size	781.4 KiB

Le SIRET n'a aucun doublon, parfait puisqu'il sera notre clé d'unicité.

activitePrincipaleRegistreMetiersEtablissement

Text

Missing

Distinct	162
Distinct (%)	10.5%
Missing	98461
Missing (%)	98.5%
Memory size	781.4 KiB

La colonne activitePrincipaleRegistreMetiersEtablissement est quasiment vide.

libelleCommuneEtrangerEtablissement

Text

Missing

Distinct	2
Distinct (%)	100.0%
Missing	99998
Missing (%)	> 99.9%
Memory size	781.4 KiB

geneve
cologne

Colonne complètement inutile dans le contexte de notre jeu de données (100 000 premières lignes du Dataset total)

Même problème de colonne quasiment vide pour :

- activitePrincipaleRegistreMetiersEtablissement
- complementAdresseEtablissement
- indiceRepetitionEtablissement
- indiceRepetitionDernierNumeroVoieEtablissement
- dernierNumeroVoieEtablissement
- distributionSpecialeEtablissement
- codeCedexEtablissement
- libelleCedexEtablissement
- codePaysEtrangerEtablissement
- libellePaysEtrangerEtablissement
- complementAdresse2Etablissement
- numeroVoie2Etablissement
- indiceRepetition2Etablissement
- typeVoie2Etablissement
- libelleVoie2Etablissement
- codePostal2Etablissement

Et plusieurs colonnes ont été marqués comme “Unsupported” :

libelleCommune2Etablissement

Unsupported

Missing

Rejected

Unsupported

Missing

100000

Missing (%)

100.0%

Memory size

781.4 KiB

Notamment :

- libelleCommuneEtranger2Etablissement
- codeCommune2Etablissement
- codePaysEtranger2Etablissement
- libellePaysEtranger2Etablissement
- ...

Nous avons aussi des problèmes de valeurs identiques pour quasiment tout la colonne :

libelleCedex2Etablissement

Text

Constant

Missing

Distinct

1

Distinct (%)

0.2%

Missing

99571

Missing (%)

99.6%

Memory size

781.4 KiB

nd

C'est le cas pour plusieurs colonnes, et la valeur distincte est toujours "nd".

2. Cartographie complète des anomalies

Variable / Champ	Type d'Anomalie	Description Technique	Impact Métier	Plan de Redressement Priorisé
dateCreationEtablissement	Complétude (Manquant)	~20.6% de valeurs manquantes (Null). Identifié clairement par le profilage comme la lacune majeure du dataset.	Critique. Impossibilité de calculer l'ancienneté des entreprises ou d'analyser la dynamique de création (Startups vs Entreprises historiques) dans Superset.	Filtrage (Airflow). Suppression des lignes sans date de création pour les tableaux de bord temporels, afin de ne pas fausser les moyennes d'âge.
Dates (Toutes)	Format (Type)	Détectées comme String (Texte) et non DateTime par Pandas lors du chargement initial.	Majeur. Les outils de visualisation (Superset) ne pourront pas faire de "Time Series" (évolution temporelle) ni d'agrégations par année/mois.	Casting (Python). Conversion explicite via <code>pd.to_datetime()</code> avec gestion des erreurs (<code>errors='coerce'</code>) dans le script de nettoyage.

siret	Validité (Format)	Risque potentiel de formats invalides (ex: moins de 14 chiffres) ou d'espaces insécables.	Bloquant. Le SIRET est la clé de jointure unique. Un mauvais format empêche le croisement avec d'autres bases (ex: URSSAF).	Validation Regex. Application d'un filtre strict <code>^\d{14}\$</code> (Doit contenir exactement 14 chiffres). Rejet des lignes non conformes.
libelleCommune...	Validité (Encodage)	Présence potentielle de caractères spéciaux mal encodés ou de noms de villes en majuscules non standardisées.	Mineur. Problèmes d'affichage esthétique sur les cartes géographiques, duplication des villes (ex: "LYON" vs "Lyon").	Standardisation. (Optionnel pour ce MVP) Nettoyage des chaînes de caractères (Trim, UpperCase) pour harmoniser les filtres géographiques.
etatAdministratif...	Validité (Domaine)	Vérification que seules les valeurs 'A' (Actif) et 'F' (Fermé) sont présentes.	Moyen. Risque de compter des établissements "Fantômes" ou aux statuts inconnus dans les statistiques d'activité.	Filtrage. Conservation stricte des valeurs du référentiel ['A', 'F'].

3. Focus sur l'analyse temporelle (Anomalie Majeure)

L'exploration approfondie dans Jupyter a mis en lumière un problème de Cohérence Temporelle (Vérification que Date Création <= Date Dernier Traitement). Bien que rare, il existe un risque théorique que des dates de traitement soient antérieures à la création (incohérence logique), souvent dû à des erreurs de saisie manuelle à la source.

Cette règle de cohérence a été intégrée comme critère bloquant dans la phase de Validation (Great Expectations).

4. Analyse Manuelle et règles métier

Au-delà du profilage statistique automatisé, nous avons mené une exploration manuelle ciblée dans un notebook Jupyter pour valider la cohérence sémantique des données. Cette étape était cruciale pour définir les règles de validation (Great Expectations) qui seront appliquées dans le pipeline industriel.

```

: import pandas as pd
import numpy as np

# Chargement avec typage optimisé pour éviter les erreurs d'interprétation
df = pd.read_csv('../data/StockEtablissement_utf8_100000.csv',
                 dtype={'codePostalEtablissement': str, 'siret': str})

# Conversion des dates (gestion des erreurs avec 'coerce')
date_cols = ['dateCreationEtablissement', 'dateDernierTraitementEtablissement']
for col in date_cols:
    df[col] = pd.to_datetime(df[col], errors='coerce')

/tmp/ipykernel_3107/2428094912.py:5: DtypeWarning: Columns (7,20,22,26) have mixed types. Specify dtype option on import or set low_memory=False.
df = pd.read_csv('../data/StockEtablissement_utf8_100000.csv',

```

Le chargement initial du CSV a levé une alerte de types mixtes (DtypeWarning). Cela confirme l'hétérogénéité des données brutes et la nécessité de forcer le typage (Casting) avant toute analyse.

B. Analyse des Formats (Validité)

```

# Vérification des SIRET invalides (Longueur != 14 ou non numérique)
siret_invalides = df[~df['siret'].str.match(r'^\d{14}$')]
print(f"SIRET Invalides : {len(siret_invalides)}")

# Vérification des Codes Postaux (Doit être 5 chiffres)
cp_invalides = df[~df['codePostalEtablissement'].str.match(r'^\d{5}$', na=False)]
print(f"Codes Postaux suspects : {len(cp_invalides)}")

SIRET Invalides : 0
Codes Postaux suspects : 450

```


L'application d'expressions régulières a confirmé l'excellente qualité structurale des identifiants majeurs : aucun format de SIRET invalide n'a été détecté sur l'ensemble du jeu de données, garantissant la fiabilité des clés de jointure. En revanche, l'analyse des codes postaux a isolé 450 valeurs atypiques ne respectant pas le standard à 5 chiffres. Ces anomalies correspondent majoritairement à des codes spécifiques (Corse, Cedex) ou à des adresses à l'étranger, ce qui nécessitera une normalisation spécifique avant toute géolocalisation.

C. Cohérence Inter-Colonnes (Logique Métier)

```
# Règle : Date Création <= Date Traitement
incoherence_temporelle = df[df['dateCreationEtablissement'] > df['dateDernierTraitementEtablissement']]

print(f"Incohérences chronologiques détectées : {len(incoherence_temporelle)}")
# Affiche un exemple pour l'analyse
print(incoherence_temporelle[['siret', 'dateCreationEtablissement', 'dateDernierTraitementEtablissement']].head())
```

Incohérences chronologiques détectées : 2

siret	dateCreationEtablissement	\
24702 02404133700031	2025-09-15	
37029 03578025300023	2026-01-05	

	dateDernierTraitementEtablissement
24702	2025-09-09 22:38:09
37029	2025-12-24 11:00:55

L'audit de la logique chronologique a mis en lumière des incohérences marginales mais critiques. Nous avons identifié deux enregistrements présentant une date de création postérieure à leur date de dernière mise à jour (ex : création en janvier 2026 pour un traitement en décembre 2025). Bien que statistiquement négligeables, ces erreurs de "futur antérieur" constituent des impossibilités logiques qui doivent être impérativement filtrées pour ne pas fausser les calculs de délais administratifs.

D. Analyse des Valeurs Manquantes (Complétude)

```
# Analyse croisée : Est-ce que les établissements fermés ont plus de dates manquantes ?
missing_dates = df[df['dateCreationEtablissement'].isna()]
print(missing_dates['etatAdministratifEtablissement'].value_counts(normalize=True))
```

F 1.0
Name: etatAdministratifEtablissement, dtype: float64

Alors que le champ date de création présente un taux de vide significatif, notre investigation prouve que 100 % de ces absences concernent des établissements à l'état administratif 'F' (Fermé). Cette découverte nous permettra d'orienter une stratégie de nettoyage : elle indique que les lacunes sont historiques. Les établissements actifs étant parfaitement renseignés, nous pouvons exclure les enregistrements sans date de nos analyses de marché sans risque de biais, car ils correspondent exclusivement à des entreprises qui n'ont plus d'activité économique.

5. Conclusion de l'Exploration

Cette phase a permis de confirmer que les données brutes SIRENE, bien que robustes sur les identifiants (SIRET), souffrent de lacunes temporelles significatives (20% de dates manquantes sur les 100 000 premières lignes). Cette découverte a directement orienté la stratégie de la phase suivante (Nettoyage) : nous ne pouvons pas "inventer" ces dates (imputation risquée), nous avons donc décidé d'exclure ces enregistrements pour garantir la fiabilité des KPI temporels présentés aux utilisateurs finaux.