

Phase 3 : Nettoyage et Standardisation des Données

1. Objectifs et Stratégie Technique

L'objectif de cette phase est de transformer les données brutes (Raw Data) en données fiables (Clean Data) prêtes pour l'analyse.

Nous avons implémenté ces transformations via un pipeline ETL (Extract-Transform-Load) orchestré par Apache Airflow, utilisant la librairie Pandas.

2. Réalisations par Pilier de Qualité

Voici comment chaque pilier de la qualité a été traité techniquement dans notre projet :

1. Complétude (Completeness)

Définition : Traitement des valeurs manquantes par suppression, imputation ou modèles ML.

Concernant la complétude, l'audit initial a mis en évidence un déficit majeur avec près de 20,6 % de valeurs manquantes sur les dates de création des établissements. Nous avons adopté une stratégie mixte selon la criticité des champs. Alors que les enregistrements présentant un SIRET vide ont été strictement rejetés pour garantir l'intégrité de la base, les dates manquantes ont fait l'objet d'une suppression ciblée. Nous avons choisi de filtrer ces lignes spécifiquement pour les analyses temporelles afin de ne pas fausser les calculs d'ancienneté, tout en les conservant pour les statistiques de volume global.

2. Exactitude (Accuracy)

Définition : Correction des formats invalides (emails, téléphones, codes postaux, dates).

Pour assurer l'exactitude des données, le traitement technique s'est concentré sur la correction des types et des formats. Les dates, initialement chargées sous forme de chaînes de caractères, ont été converties vers des objets temporels (datetime) pour permettre une précision chronologique fiable. Parallèlement, des expressions régulières (Regex) strictes ont été appliquées pour normaliser les identifiants, en vérifiant notamment que les SIRET contiennent exactement 14 chiffres et les codes postaux 5 chiffres, éliminant ainsi les erreurs de formatage à la source.

3. Validité (Validity)

Définition : Vérification de la conformité aux référentiels métier et règles business.

La validité des données a été sécurisée par une vérification de conformité vis-à-vis des référentiels métier. Nous avons restreint le champ de l'état administratif aux seules valeurs autorisées par le domaine métier, à savoir 'A' pour les établissements actifs et 'F' pour les fermés. Toute valeur située en dehors de cet ensemble défini a été considérée comme du bruit et filtrée pour respecter strictement les règles de gestion du répertoire SIRENE.

4. Cohérence (Consistency)

Définition : Validation des règles inter-colonnes (temporelles, mathématiques, métier).

En matière de cohérence, nous avons implémenté des règles logiques inter-colonnes pour valider la chronologie des événements. Concrètement, une contrainte a été appliquée pour garantir que la date de création d'un établissement est systématiquement antérieure ou égale à sa date de dernier traitement. Cette logique métier permet d'écarter les enregistrements incohérents où une modification administrative semblerait précéder l'existence même de l'entreprise.

5. Unicité (Uniqueness)

Définition : Dédoublonnage strict et fusion intelligente avec fuzzy matching.

L'unicité a été gérée par un dédoublonnage strict basé sur la clé primaire SIRET. Contrairement à des méthodes de rapprochement flou (fuzzy matching), nous avons appliqué une déduplication déterministe en ne conservant, pour chaque SIRET, que l'occurrence la plus récente basée sur la date de traitement. Cette opération assure qu'chaque établissement est unique dans l'entrepôt de données final, évitant toute surévaluation des effectifs.

6. Actualité (Timeliness)

Définition : Identification et marquage des données obsolètes avec seuils configurables.

Enfin, l'actualité des données a été traitée par la mise en place de seuils de validité temporelle. Nous avons procédé à l'identification et au marquage des données obsolètes en excluant les enregistrements antérieurs à l'an 2000, considérés comme des archives historiques non pertinentes pour le pilotage actif, ainsi que les dates futures aberrantes, garantissant ainsi que les tableaux de bord reflètent une situation économique fraîche et réaliste.

3. Bilan de la Phase

À l'issue de cette phase, le dataset est passé de l'état "Raw" (Brut, hétérogène, typé string) à l'état "Cleaned" (Typé, validé, dédoublonné). Ce nettoyage a permis de rejeter environ 20% des données initiales (principalement pour défaut de date), assurant ainsi que les KPIs calculés en Phase 4 sont mathématiquement justes.