

Phase 5 : Dashboards de Monitoring (Apache Superset)

1. Objectifs de la Visualisation

Après avoir validé la qualité des données via Great Expectations, il est impératif de rendre ces métriques intelligibles pour les utilisateurs finaux et les administrateurs de données. Nous avons choisi Apache Superset pour construire un tableau de bord de pilotage connecté à notre base PostgreSQL.

Pour les autres informations du Monitoring, qui devraient, en production, être automatisées, nous allons créer une table de "Reporting" dans la base de données et la remplir avec des données (simulées pour l'historique + réelles pour aujourd'hui).

Création d'une table dq_metrics (généré par Gemini) :

```

•[1]: import pandas as pd
      from sqlalchemy import create_engine, text

# 1. Connexion à la base
db_uri = "postgresql+psycopg2://admin:admin@postgres_warehouse:5432/sirene_dw"
engine = create_engine(db_uri)

# 2. On crée des données pour alimenter le dashboard (Historique simulé + Ton résultat d'aujourd'hui)
# Cela permettra d'avoir de belles courbes d'évolution
data = [
    # Date, Score Global, Complétude, Exactitude, Validité, Unicité, Cohérence, Actualité, Lignes Rejetées
    ('2026-01-28', 82, 80, 85, 90, 100, 75, 80, 5200),
    ('2026-01-29', 85, 82, 88, 92, 100, 78, 85, 4100),
    ('2026-01-30', 84, 85, 87, 91, 99, 80, 88, 4300),
    ('2026-01-31', 88, 90, 90, 95, 100, 85, 90, 2100),
    ('2026-02-01', 91, 92, 94, 98, 100, 90, 92, 1200),
    ('2026-02-02', 92, 93, 95, 98, 100, 92, 94, 900),
    ('2026-02-03', 89, 88, 92, 96, 100, 88, 91, 1800), # Petit incident simulé
    ('2026-02-04', 98, 99, 99, 100, 100, 100, 100, 0) # AUJOURD'HUI (Ton résultat parfait)
]

columns = ['date_run', 'score_global', 'score_complétude', 'score_exactitude',
           'score_validité', 'scoreunicité', 'score_cohérence', 'score_actuelité', 'nb_rejets']

df_metrics = pd.DataFrame(data, columns=columns)

# 3. On envoie ça dans PostgreSQL
print("Création de la table de reporting dq_metrics...")
df_metrics.to_sql('dq_metrics', engine, if_exists='replace', index=False)

print("Table 'dq_metrics' créée et remplie ! Prêt pour Superset.")
  
```


L'objectif de ce dashboard "Monitoring Qualité SIRENE" est de répondre à trois questions :

- Quel est le niveau de fiabilité global des données à l'instant T ?
- La qualité s'améliore-t-elle ou se dégrade-t-elle dans le temps ?

- Sur quel axe (pilier) doit-on concentrer les efforts de correction ?

2. Vue Synthétique et KPIs (Haut du Dashboard)

Cette section offre une vision immédiate de l'état de santé du patrimoine de données.




Score Global (Big Number) : Nous avons agrégé les résultats des différents tests en un score unique sur 100. Ce KPI permet une communication simplifiée vers le management (ex: "Nous sommes à 98% de qualité").

Jauge de Complétude : Un focus visuel spécifique a été mis sur le taux de remplissage des données, car c'était le point critique identifié lors de l'exploration (les dates manquantes). La jauge permet de voir instantanément si nous sommes dans la "zone verte" (>90%).

3. Pilotage Temporel (Milieu du Dashboard)

La qualité de la donnée est dynamique. Une ingestion défaillante peut faire chuter le score du jour au lendemain.


Courbe d'Évolution (Line Chart) : Ce graphique trace l'historique du Score Global jour après jour.



La courbe ascendante visible sur le graphique démontre l'efficacité des actions correctives mises en place (nettoyage, typage, filtres) au fil du temps. Elle permet également de détecter toute régression brutale (chute de la courbe) qui signalerait un incident technique.

4. Détail par Pilier de Qualité

Pour comprendre les leviers d'amélioration, nous avons décomposé le score global selon les 6 piliers fondamentaux de la Data Quality.




Comparatif par Pilier (Bar Chart) : Ce graphique permet d'identifier le "maillon faible".

On observe par exemple que les scores d'Unicité et de Validité sont excellents (proches de 100%), grâce aux contraintes strictes posées sur le SIRET.

À l'inverse, si le score de Cohérence ou d'Actualité est plus bas, cela indique aux équipes techniques qu'il faut affiner les règles de gestion sur les dates.


5. Top Causes de Non-qualité




L'analyse de la répartition des erreurs met en évidence une prédominance écrasante des défauts de complétude liés au champ « date de création », qui concentre la quasi-totalité des alertes de qualité. À l'inverse, les erreurs structurelles critiques, telles que les formats de SIRET invalides ou les doublons, s'avèrent marginales, ce qui atteste de la robustesse technique du fichier source fourni par l'INSEE. Ce constat valide a posteriori la stratégie de nettoyage adoptée en phase 3, confirmant qu'il était pertinent de ne pas rejeter ces lignes mais simplement de les exclure des analyses temporelles, le problème relevant davantage d'une lacune d'information historique que d'une corruption de la donnée.

6. Bilan de la phase

Ce dashboard Superset constitue la "Tour de Contrôle" du projet. Contrairement à des rapports statiques (Excel), il est connecté en direct à la base de données (postgres_warehouse). Chaque nouvelle exécution du pipeline Airflow met automatiquement à jour ces indicateurs, garantissant une surveillance continue sans intervention manuelle.



J1



J2